

# Avance de Proyecto

## Identificación facial con pocas muestras por clase

Martín Villanueva<sup>1</sup>

<sup>1</sup>Departamento de Informática  
Universidad Técnica Federico Santa María

Máquinas de Aprendizaje, 2015

# Outline

## 1 El Problema

- Identificación facial
- Datasets

## 2 Propuestas de solución

- Linear Discriminant Analysis
- Multi-class SVM
- Convolutional Neural Networks
- Dissimilarity SVM

# Outline

## 1 El Problema

- Identificación facial
- Datasets

## 2 Propuestas de solución

- Linear Discriminant Analysis
- Multi-class SVM
- Convolutional Neural Networks
- Dissimilarity SVM

# Definición del Problema

El problema tratado consiste en, dadas una *pocas* muestras de imágenes faciales de distintos individuos, generar un algoritmo que permita identificar correctamente a cada individuo, dada una imagen distinta a las anteriores. Más formalmente:

- Se define  $S_{tr} = \{\mathbf{s}_1, \dots, \mathbf{s}_M\}$  como el conjunto de entrenamiento con imágenes faciales de  $K$  individuos.
- El problema de **identificación** es, dada una imagen de *test*  $\mathbf{p}$ , determinar cuál de las  $K$  clases del conjunto de entrenamiento  $S_{tr}$  corresponde.
- Se restringe el problema a casos donde cada clase posee pocas muestras en  $S_{tr}$ , lo cual es una situación bastante realista.

# Datasets

Los datasets a ocupar corresponden a Faces94 y Faces95. Los cuales tiene las siguientes características respectivamente:

- **Faces94:** 153 individuos, 20 imágenes por individuo, resolución  $200 \times 180$ , hombres y mujeres, fondo fijo, poca variación en escalamiento, poca variación de posición de la imagen y condiciones de iluminación, y considerables variaciones en expresiones faciales.
- **Faces95:** 72 individuos, 20 imágenes por individuo, resolución  $200 \times 180$ , hombres y mujeres, fondo con sombra, considerable variación en escalamiento, poca variación en posición de imagen, iluminación variable, y variaciones considerable en expresiones faciales.

# Faces94



Figura: Imágenes características de un individuo en Faces94

# Faces95



Figura: Imágenes características de un individuo en Faces95

# Otras consideraciones

Para emular las restricciones del problema, se sigue la siguiente metodología

- Para cada uno **Faces94** y **Faces95** se generan 20 training y testing sets respectivos.
- Cada training set se genera tomando 3 – 5 muestras aleatorias por cada individuo, dejando el resto de las 15 – 17 imágenes restantes en el testing set.
- Luego, para cada dataset (**Faces94** o **Faces95**) hay en total 60 sets de training y testing respectivos.
- La presentación de resultados, se realiza con Errorbars (t-student 95 % de confianza) del error rate sobre los 20 datasets respectivos.



# Outline

## 1 El Problema

- Identificación facial
- Datasets

## 2 Propuestas de solución

- Linear Discriminant Analysis
- Multi-class SVM
- Convolutional Neural Networks
- Dissimilarity SVM

# LDA

- La implementación ocupada corresponde la de Scikit-Learn. Para cada una de las clases (personas) genera un función discriminante lineal  $\delta_k$ , que permite diferenciar a cada una de las clases.
- Supuestos Fuertes: 1) La probabilidad multivariada de las características  $P(x_m|y = k)$  se distribuye normal, y 2) La matriz de covarianza para cada una de las clases es igual.
- Como LDA es un modelo generativo (sin hiperparámetros), no es necesario realizar cross-validation para el modelo. Permite ahorrar gran tiempo de computación.

# LDA: Resultados en Faces94




Figura: Resultados obtenidos con LDA en **Faces94**

# LDA: Resultados en Faces95




Figura: Resultados obtenidos con LDA en **Faces95**

# Multi-class SVM

- Support Vector Machines (SVM) es un método de clasificación binario (adaptable a problemas de múltiples clases), que encuentra la frontera de decisión lineal óptima (hiperplano óptimo) separadora de las clases.
- Implementación y entrenamiento de multiclass SVM's con kernels tanto lineales como RBF. La implementación de Scikit-Learn advierte: "SVC implement one-against-one" approach (Knerr et al., 1990) for multi- class classification".
- Se utilizan  $\nu$ -SMV's, debido a que facilita la configuración del parámetro de holgura  $\nu \in (0, 1]$ , y a su interpretación.
- Selección de hiperparámetros  $\nu$  y  $\gamma$  (en kernels rbf) se realiza stratified cross-validation. Para que esto tenga sentido, el número de folds debe ser igual al número de muestras por clase.

# Reducción de dimensionalidad

- **Problema:** Las dimensiones de las imágenes ( $200 \times 180 = 36000$ ) corresponden al total de features de cada foto. Esto hace necesario ocupar reducción de dimensionalidad para tomar las características realmente importantes (aquellas que permiten diferencias entre las clases) y mejorar los tiempos de entrenamientos y eficiencia.
- Como técnica de reducción de dimensionalidad, se ha decidido ocupar LDA, representación también conocida como Fisher-Faces (reducción de dimensionalidad supervisada).
- **Idea:** Proyectar la data en espacio donde se maximice la inter-class variance y minimice la intra-class variance.

## Reducción de dimensionalidad (2)




Figura: LDA como reducción de dimensionalidad

- El número de máximo de discriminantes es  $\min(\text{dim}, K - 1)$ , por lo tanto en un problema con muchas más dimensiones (features) que clases, la reducción de dimensionalidad es considerablemente.

# Resultados linear SVM Faces94





Figura: Resultados obtenidos con linear SVM en **Faces94**



# Resultados linear SVM Faces94 (2)



**Figura:** Comparación de resultados obtenidos con linear SVM en **Faces94**

# Resultados linear SVM Faces95

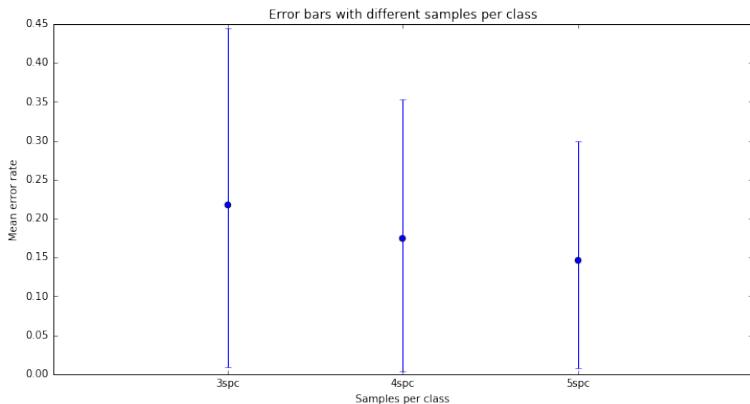
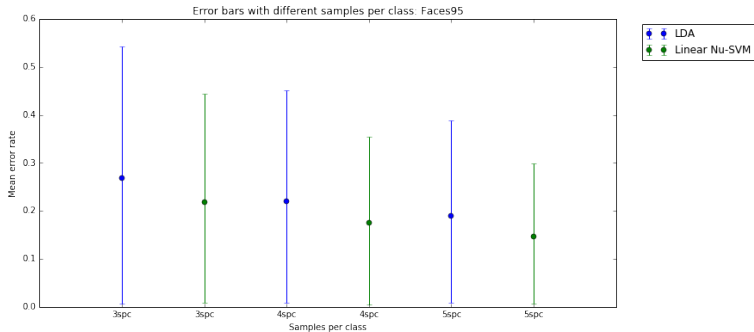


Figura: Resultados obtenidos con linear SVM en **Faces95**

# Resultados linear SVM Faces95 (2)



**Figura:** Comparación de resultados obtenidos con linear SVM en **Faces95**

# Resultados RBF SVM Faces94




Figura: Resultados obtenidos con RBF SVM en **Faces94**

# Resultados RBF SVM Faces94 (2)

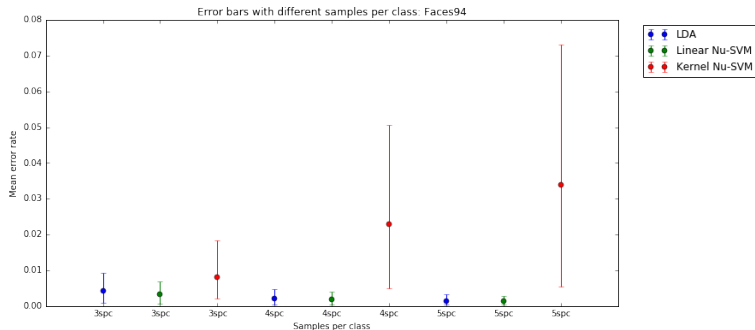


Figura: Comparación de resultados obtenidos con RBF SVM en **Faces94**

# Resultados RBF SVM Faces95




Figura: Resultados obtenidos con RBF SVM en **Faces95**

# Resultados RBF SVM Faces95 (2)

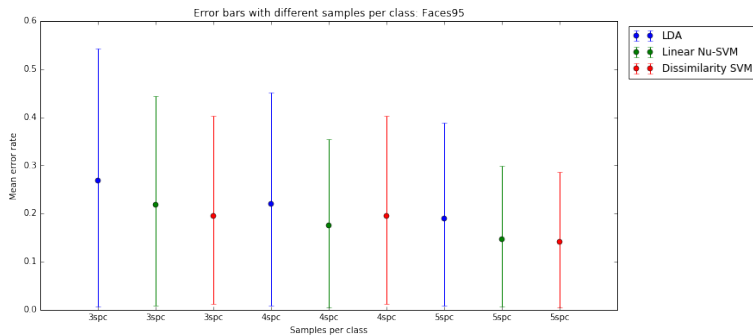


Figura: Comparación de resultados obtenidos con RBF SVM en **Faces95**

# Análisis de resultados

- Linear-SVM tiene un buen resultado en general, superando a LDA (mejor capacidad de generalización).
- Para faces94, ocupar modelos que aumenten la complejidad (como RBF SVM) sólo empeora los resultados.
- Para faces95 RBF SVM se comporta mejor, pero no supera a los otros dos algoritmos anteriores.



# CNN

:-(...

# D-SVM

- Hasta ahora, todos los métodos tratados resuelven el problema de identificación como  $K$ -class classification.
- El método aquí propuesto, transformar el espacio de representación de los datos, reduciendo el problema a clasificación binaria.
- Para esto se debe mapear los datos desde el *Image Space* al *Difference Space*.
- Se definen entonces dos conjuntos,  $C_1$  y  $C_2$ ; El primero corresponde al *within-class differences set* y contiene las disimilitudes entre datos de la misma clase. El segundo es *between-class difference set* y contiene las disimilitudes entre datos de distinta clase.

# D-SVM (2)

## Definition

Dea  $S_{tr} = \{\mathbf{s}_1, \dots, \mathbf{s}_M\}$  el conjunto de entrenamiento con  $K$  individuos. Para indicar que dos individuos pertenecen a la misma clase se denota  $\mathbf{s}_i \sim \mathbf{s}_j$ , y en caso contrario  $\mathbf{s}_i \not\sim \mathbf{s}_j$ . Se define adicionalmente la función de disimilitud  $\phi : R^N \times R^N \rightarrow R^S$  con  $S \leq N$ , como aquella función que mapea dos imagenes, hacia el *difference space*. Luego es posible definir

$$C_1 = \{\phi(\mathbf{s}_i, \mathbf{s}_j) \mid \mathbf{s}_i \sim \mathbf{s}_j\} \quad (1)$$

$$C_2 = \{\phi(\mathbf{s}_i, \mathbf{s}_j) \mid \mathbf{s}_i \not\sim \mathbf{s}_j\} \quad (2)$$

## D-SVM (2)

- El entrenamiento de la D-SVM (Dissimilarity SVM), tiene como entradas los conjuntos  $C_1$  y  $C_2$ .
- Como resultado de la clasificación se obtiene la superficie de decisión

$$f(\mathbf{x}) = \sum_m^{M_s} \alpha_m y_m K(\mathbf{v}_m, \mathbf{x}) + b = 0$$

donde la función  $f(\mathbf{x})$  puede ocuparse de discriminante para determinar si un dato pertenece a una clase u otra.

# D-SVM (3)

El proceso de identificación es como sigue:

- Sea  $\mathbf{p}$  la imagen a identificar sobre un conjunto de imágenes conocidas  $S_{tr}$ . Se computa la representación en el *difference space*:  $\phi(\mathbf{p}, \mathbf{s}_i) \forall \mathbf{s}_i \in S_{tr}$ .
- Evaluar la función de discriminante  $f(\mathbf{x})$  sobre cada uno de los resultados anteriores.
- La clase de pertenencia será aquella para la cual  $f(\phi(\mathbf{p}, \mathbf{s}_i))$  sea la menor posible:

$$\underset{i}{\operatorname{argmin}} f(\phi(\mathbf{p}, \mathbf{s}_i)) \quad (3)$$

# Local Binary Pattern (1)

- **Idea:** Forma de representación de imágenes, como una composición de micro-patrones que describen las estructuras presentes en estas. Los distintos patrones que emergen corresponden a las características presentes en las imágenes.




Fig. 1. The basic LBP operator.



Figura: Local Binary Pattern Operator

# Local Binary Pattern (2)




Fig. 2.4 The 58 different uniform patterns in  $(8, R)$  neighborhood

**Figura:** Uniform Local Binary Patterns

# Histograma Espacial de Características

- Cada uno de estos 59 patrones representan una característica, y la frecuencia o distribución (histogramas) de estas definen las estructuras presentes en las imágenes.
- Sin embargo se requiere también de información espacial, acerca de donde se encuentran estas características.




Figura: Histograma espacial de características



# Método Propuesto

El modelo propuesto difiere de aquel propuesto por P. Jonathon Philips en *Support Vector Machines Applied to Face Recognition*, en la función  $\phi(\cdot, \cdot)$  de mapeo al *difference space*. Sean dos imágenes representadas en la forma de histograma espacial ( $\mathbf{h}_1, \mathbf{h}_2$ ) con  $S$  histogramas, luego la función es

## Definition

$\phi(\mathbf{h}_1, \mathbf{h}_2) = \mathbf{d} = (d_1, \dots, d_S)$  tal que  $\mathbf{d}_i$  corresponde a la diferencia existente entre los histogramas  $i$ -ésimos de las respectivas imágenes. Tal diferencia se computa con la función:

$$\chi^2(x, y) = \sum_k \frac{(x_k - y_k)^2}{x_k + y_k}$$

# Detalles de Implementación

- Cuando existen  $s$  muestras por clase, se pueden hacer  $\binom{s}{2}$  combinaciones para formar el conjunto  $C_1$ .
- El conjunto  $C_2$  se forma tomando aleatoriamente igual cantidad  $\left(\binom{s}{2}\right)$  de pares de datos de distinta clase.
- El valor que obtiene la función discriminante  $f(\mathbf{x})$ , se promedia para los datos que pertenecen a la misma clase en  $S_{tr}$

# Resultados D-SVM Faces94

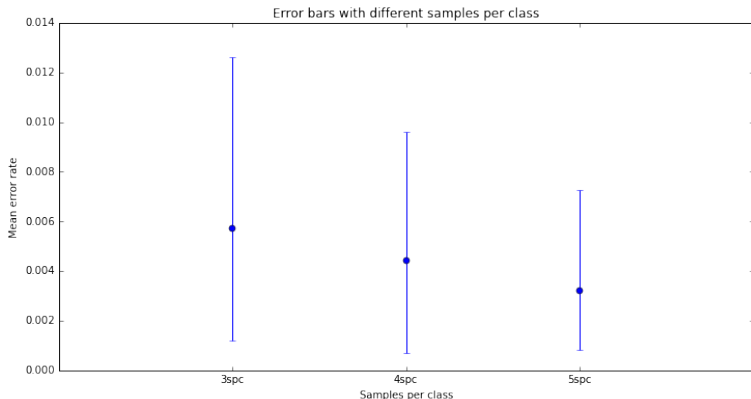
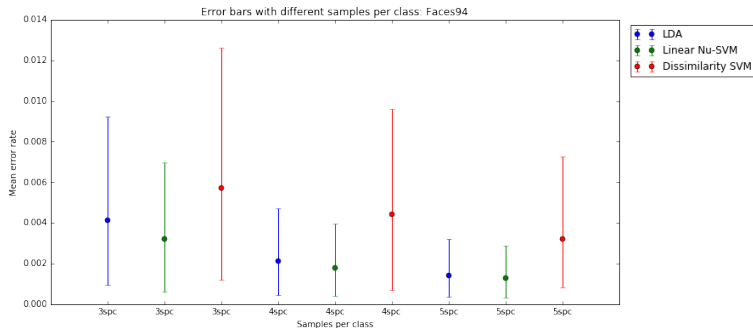


Figura: Resultados obtenidos con D-SVM en **Faces94**

# Resultados D-SVM Faces94 (2)



**Figura:** Comparación de resultados obtenidos con D-SVM en **Faces94**

# Resultados D-SVM Faces95




Figura: Resultados obtenidos con D-SVM en **Faces95**

# Resultados D-SVM Faces95 (2)




Figura: Comparación de resultados obtenidos con D-SVM en **Faces95**